ANÁLISE DAS SOLICITAÇÕES FEITAS AO NYC 311 EM 2025

Análise realizada por Mayara Reghin

Repositório: https://github.com/mayarareghin/nyc-311-sql-analysis

OBJETIVO

- Analisar as solicitações de serviço do NYC 311 para identificar padrões nas solicitações no ano de 2025;

- Fornecer insights sobre a performance e eficiência operacional do 311 Service Request;

TECNOLOGIAS UTILIZADAS

- PYTHON: Ingestão de dados e integração com DuckDB
- SQL: Limpeza, transformação e análise de dados
- DUCKDB: Banco de dados analítico para consultar e processar dados
- PANDAS: Manipulação dos dados e exportação de datasets
- REST API: Extração de dados do NYC Open Data
- GIT e GITHUB: Controle de versão e organização do projeto

INGESTÃO E TRATAMENTO DOS DADOS

Os dados utilizados neste projeto são referentes às requisições de serviços feitas para a prefeitura de Nova Iorque através do "311 Service Request" no ano de 2025 e foram obtidos através da API disponibilizada no NYC Open Data (https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2020-to-Present/erm2-nwe9/about_data).

A ingestão dos dados foi feita com a linguagem Python através da API do NYC Open Data. Devido ao alto volume de registros (superior a 3 milhões), foi implementado um processamento paralelizado. Através do paralelismo, o código realiza diversas requisições simultâneas à API, ao invés de seguir a sequência "fazer requisição – esperar pelos dados – processar – fazer nova requisição". Dessa forma foi possível otimizar o tempo de ingestão dos dados.

A medida que os dados são processados, eles são salvos em um formato parquet, com particionamento por ano. Esse formato foi escolhido devido a otimização em consultas que ele proporciona devido ao seu armazenamento colunar, que permite ler apenas as colunas necessárias e ao suporte para processamento paralelo, o que o torna ideal para trabalhar com big data.

O tratamento e limpeza dos dados foi feito utilizando a linguagem SQL. Na limpeza dos dados foram removidas colunas que analisei não fazerem sentido para o objetivo e criado uma tabela única. Com os dados limpos, criei colunas novas convertendo as datas em timestamp (estavam com formato VARCHAR), criei colunas de data e horário separados para facilitar as análises e uma coluna calculada com o tempo de resolução em horas (data de fechamento – data de criação) foi criada.

Para rodar essas transformações e as demais consultas SQL, utilizei o DuckDB, que é um sistema de banco de dados analítico, open source e serveless que permite usar SQL diretamente em arquivos e tem bom desempenho com grandes volumes de dados. O DuckDB foi implementado com código Python.

ANÁLISE DOS DADOS

A análise foi iniciada a partir dos tipos de reclamações registradas na base de dados. Foram identificados 191 tipos distintos de reclamações. Os 10 tipos mais frequentes concentram-se em problemas urbanos recorrentes, como ruído, estacionamento ilegal, questões sanitárias e problemas estruturais. Esse padrão indica que a maior parte das solicitações está relacionada a situações do cotidiano, e não a eventos pontuais ou excepcionais.

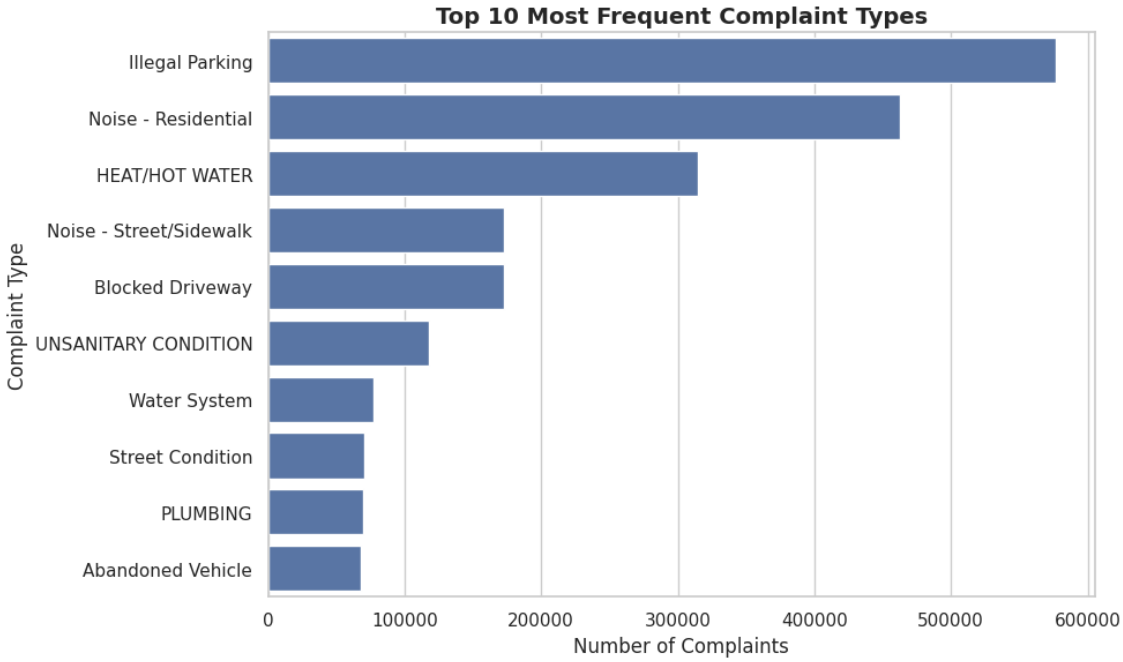

Por outro lado, ao analisar os tipos menos frequentes, observam-se categorias com menos de 5 registros, caracterizando possíveis outliers dentro da base.

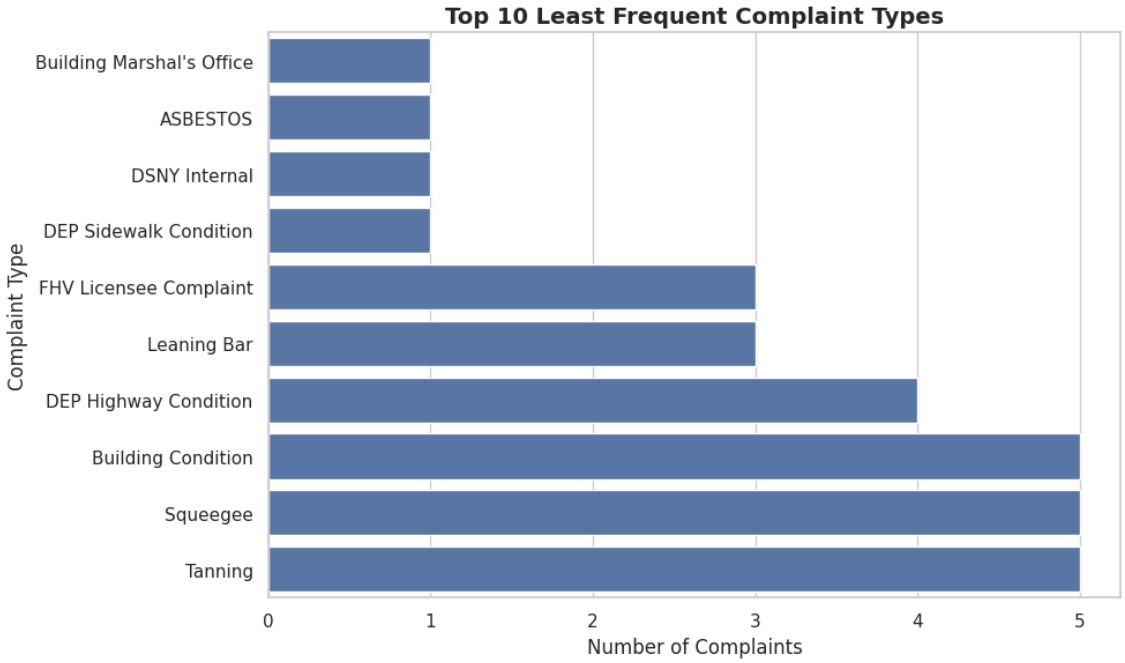

As solicitações registradas no sistema 311 são direcionadas a diferentes agências públicas. A análise demonstra que o departamento de polícia concentra aproximadamente metade dos chamados, indicando uma forte dependência operacional dessa agência. As reclamações mais comuns direcionadas a esse órgão envolvem situações não emergenciais de caráter irregular, como ruídos excessivos, estacionamento ilegal e veículos abandonados. Em contraste, apenas três agências — o Escritório de Tecnologia e Inovação, o Escritório do Xerife e o Departamento de Educação — registraram menos de 10 mil chamados, indicando menor participação no volume total de solicitações.

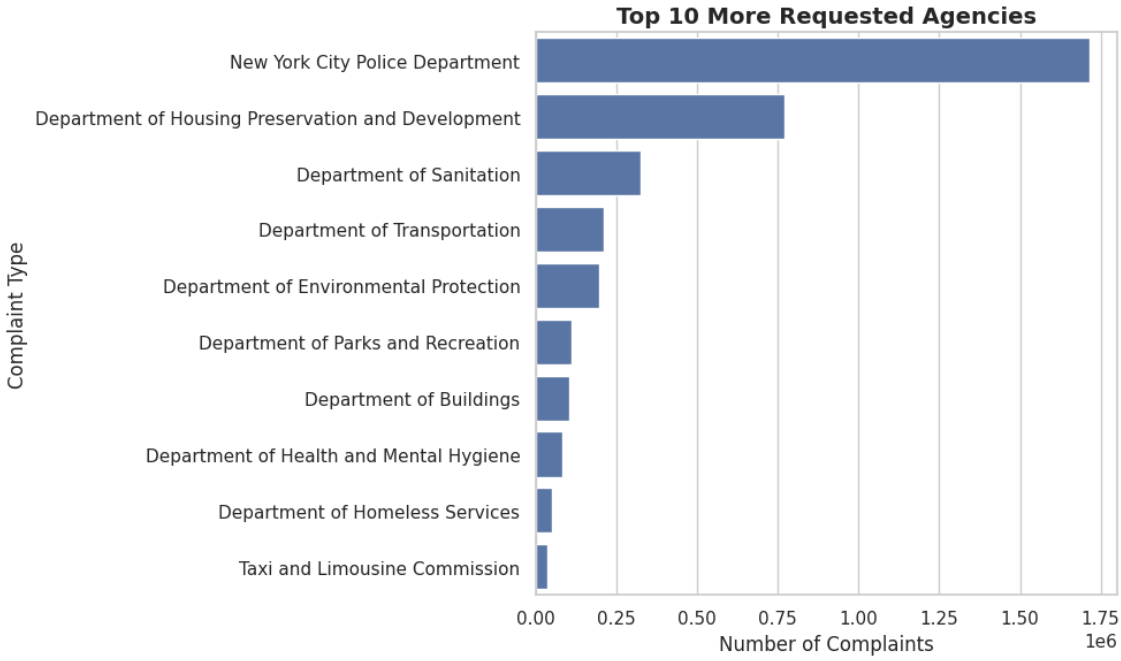

Sob a perspectiva geográfica, entre os cinco distritos analisados, o Brooklyn apresenta o maior volume de reclamações. Esse comportamento pode ser parcialmente explicado por fatores demográficos, uma vez que se trata do distrito mais populoso de Nova York. Queens, Bronx e Manhattan apresentam volumes relativamente semelhantes, enquanto Staten Island registra significativamente menos ocorrências, possivelmente refletindo sua menor densidade populacional e perfil mais residencial.

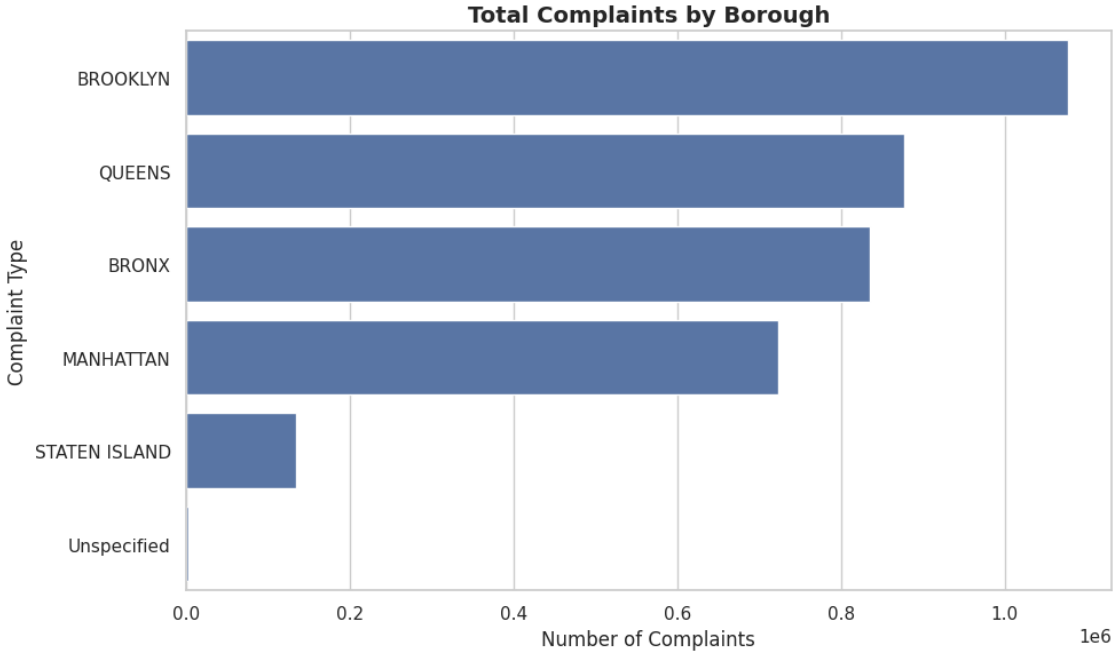

A análise temporal demonstra que o volume de chamados se mantém estável ao longo dos meses, com aproximadamente 30 mil registros mensais em 2025, com variações de até 5mil chamados. Esse comportamento indica ausência de sazonalidade relevante, sugerindo que não há necessidade de planejamento de operações específicas em determinados períodos do ano. Em nível semanal, observa-se leve redução no volume de solicitações durante os finais de semana, mas sem variações significativas.

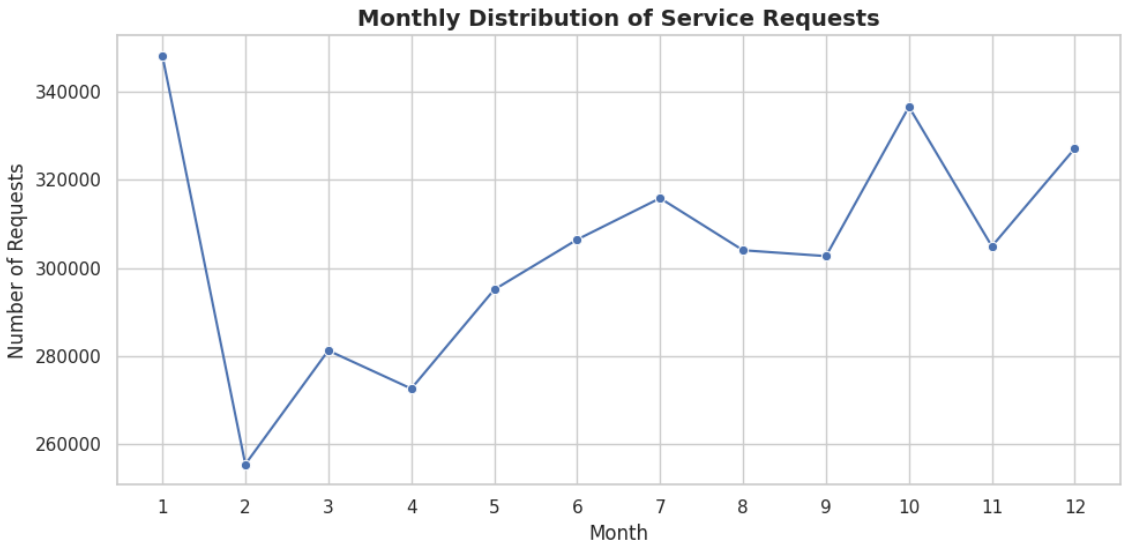

Em termos de eficiência operacional, aproximadamente 98% das solicitações foram resolvidas em 2025, indicando um alto nível de atendimento. Analisando medidas de tendência central, o tempo médio de resolução é de cerca de 8 dias e a mediana é 6 horas. Os mínimos e máximos indicaram que há muitos outliers. O mínimo é -4800, que analisando o registro foi na verdade um erro de digitação, pois o chamado foi aberto em

2025 e fechado como se fosse em 2024. Já o registro com valor máximo foi aberto em 2025 e fechado em 2026.

Dado esses outliers, em uma nova consulta limitei o tempo de resolução entre 0 (para retirar números negativos) e 8766 horas (equivalente a um ano, para procurar registros resolvidos em até um ano). As medidas de tendência central seguiram indicando forte assimetria nos dados e confirmamos isso através de um histograma. Apesar de termos uma média mais elevada e valores máximos altos, a maioria dos casos fica com tempo de resolução próximo a zero. Dessa forma, concluímos que a resolução das solicitações é feita em poucos dias, apesar dos outliers.

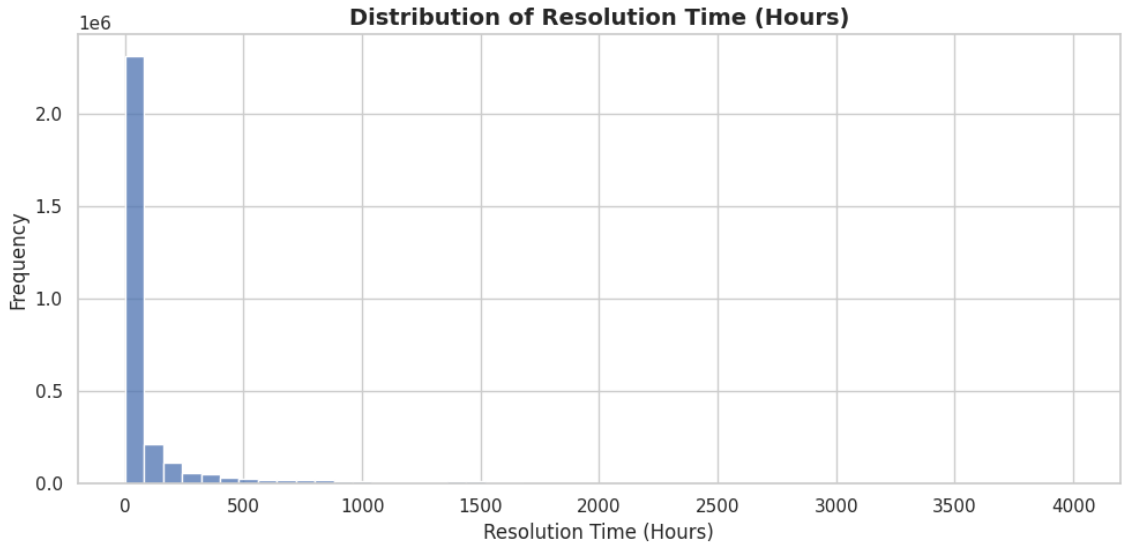

Com o boxplot podemos observar melhor,

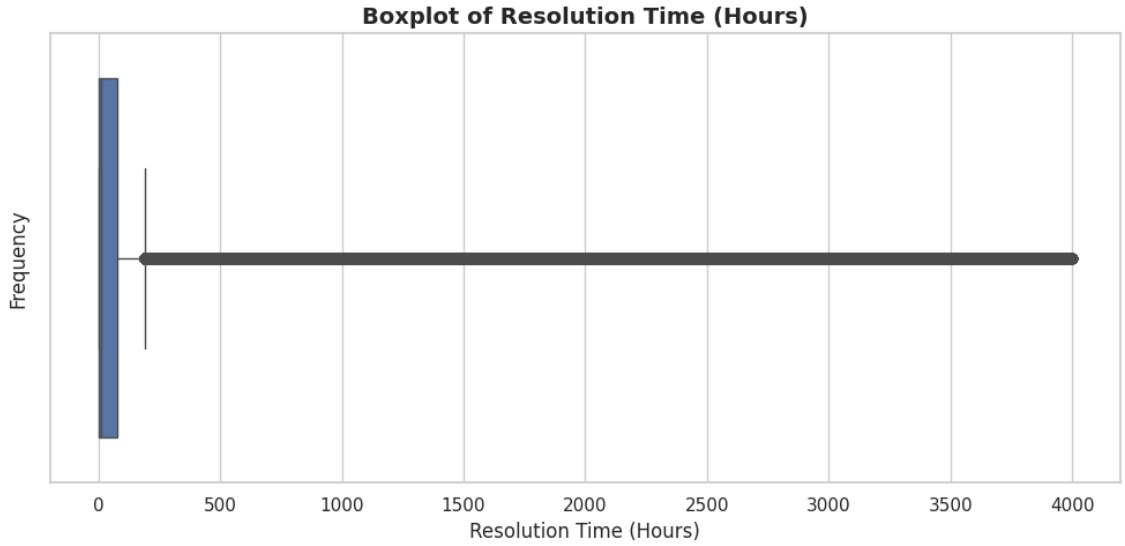

No entanto, ao analisar esse indicador de forma mais detalhada, observa-se uma variação significativa entre os diferentes tipos de reclamação.

Enquanto os tipos de reclamação mais frequentes apresentam tempo médio de resolução inferior a 2 dias, algumas categorias menos frequentes registram tempos extremamente elevados, variando entre 93 e 267 dias. Uma análise mais aprofundada revela que esses casos estão associados, em sua maioria, a volumes muito baixos de

ocorrência (frequentemente inferiores a 25 registros), o que sugere a presença de outliers e não necessariamente uma ineficiência sistêmica.

Dessa forma, os resultados indicam que o desempenho geral do sistema é fortemente influenciado pela alta eficiência no tratamento das demandas mais recorrentes, enquanto um pequeno conjunto de casos raros e potencialmente mais complexos impacta de forma significativa os indicadores de tempo de resolução caso não haja remoção desses outliers.

INSIGHTS

A partir dessa análise podemos observar alguns padrões.

- Reclamações majoritariamente ligadas a problemas urbanos recorrentes

A maior parte das solicitações está relacionada a problemas cotidianos, como ruído, estacionamento ilegal e questões sanitárias, indicando que o sistema 311 é amplamente utilizado para resolver demandas recorrentes da população.

- Alta concentração de requisições em uma única agência

O departamento de polícia concentra aproximadamente metade dos chamados, evidenciando uma forte dependência operacional dessa agência no atendimento das solicitações.

- Distribuição geográfica das reclamações alinhada à densidade populacional

Bairros mais populosos, como Brooklyn, apresentam maior volume de solicitações, enquanto regiões menos densas, como Staten Island, registram significativamente menos chamados.

- Estabilidade no volume de solicitações ao longo do tempo

O número de chamados se mantém relativamente constante ao longo dos meses, indicando ausência de sazonalidade relevante e maior previsibilidade operacional.

- Alta taxa de resolução das solicitações e eficiência operacional

Aproximadamente 98% dos chamados foram resolvidos, demonstrando alto nível de eficiência no atendimento das demandas. Os tipos de reclamação mais comuns apresentam tempo médio de resolução inferior a 2 dias, indicando que a operação é altamente eficiente na resolução das demandas recorrentes.